

# Herramientas de IA en la Planificación Quirúrgica: Segmentación y Clasificación Automatizada en Imágenes Médicas RM

Alejandro Martínez Guillermo

Grado  
Ingeniería Biomédica

E.T.S.I.I  
UPCT

Martínez Cabeza de Vaca Alajarín, Juan de la Cruz  
Zapata Pérez, Juan Francisco  
Arévalo García, Alicia

2025



# INDICE

## Contents

<b>1</b>	<b>Introducción</b>	<b>5</b>
1.1	Evolución de la Inteligencia Artificial y su Aplicación en Medicina . . . . .	5
1.2	Principios de las Imágenes Médicas y la Resonancia Magnética . . . . .	6
1.2.1	Imágenes Médicas . . . . .	6
1.2.2	Principio de RM . . . . .	7
1.2.3	Ponderaciones en T1 y T2 en Resonancia Magnética . . . . .	8
1.2.4	Importancia de la clasificación de imágenes en T1 y T2 . . . . .	10
1.3	Objetivos del Trabajo . . . . .	10
<b>2</b>	<b>Estado del arte</b>	<b>11</b>
2.1	Introducción . . . . .	11
2.2	Inteligencia Artificial en Medicina . . . . .	11
2.2.1	Evolución de la IA en Imágenes Médicas . . . . .	11
2.2.2	Aplicaciones de la IA en Radiología y Resonancia Magnética . . . . .	12
2.3	Modelos de Segmentación de Imágenes Médicas . . . . .	13
2.3.1	Modelos Convencionales . . . . .	13
2.3.2	Redes Neuronales Convolucionales (CNNs) en Segmentación Médica . . . . .	14
2.4	Modelos clave en segmentación médica . . . . .	15
2.4.1	U-Net: Arquitectura y aplicaciones en segmentación médica . . . . .	15
2.5	Modelos de Clasificación de Imágenes Médicas . . . . .	16
2.5.1	Modelos de Aprendizaje Profundo para Clasificación . . . . .	16
2.5.2	Redes CNN estándar y su uso en clasificación de imágenes médicas . . . . .	17
<b>A</b>	<b>Additional</b>	<b>19</b>
<b>Bibliography</b>	<b>eu Español</b>	<b>21</b>



En general:  $\longrightarrow$  Si es un mínimo  
1/ Intenta que los párrafos sean coherentes y lo  
suficientemente independientes para considerarse  
párrafos.  
2/ Siempre atenga la misma forma verbal  
} se ha realizado  
} se ha desarrollado, etc

## Chapter 1

# Introducción

## 1.1 Evolución de la Inteligencia Artificial y su Aplicación en Medicina

La inteligencia artificial (IA) ha experimentado un crecimiento exponencial en las últimas décadas, consolidándose como una de las tecnologías más importantes en múltiples campos, incluida la medicina. Desde sus primeras formulaciones teóricas en la década de 1950 con los trabajos pioneros de Alan Turing en el concepto de máquinas inteligentes y John McCarthy, quien acuñó el término "inteligencia artificial" en 1956 [?], la IA ha evolucionado significativamente. Inicialmente, los sistemas expertos y las reglas programadas dominaron la escena, proporcionando soluciones limitadas y altamente dependientes del conocimiento humano explícito. Sin embargo, con la llegada del aprendizaje automático (machine learning) en las décadas de 1980 y 1990, se inició una transición hacia modelos capaces de aprender patrones a partir de grandes volúmenes de datos, mejorando su capacidad de generalización y adaptabilidad [?].

El avance más significativo se produjo con la irrupción del aprendizaje profundo (Deep learning), impulsado por tres factores clave:

1. El incremento en la capacidad de cómputo, especialmente con las unidades de procesamiento gráfico (GPUs), que han permitido entrenar modelos más complejos en tiempos reducidos[?].
2. La disponibilidad masiva de datos médicos, facilitada por iniciativas como las bases de datos de imágenes médicas públicas (p. ej., The Cancer Imaging Archive - TCIA) [?].
3. Los avances en algoritmos de optimización y arquitecturas de redes neuronales, que han mejorado el rendimiento y la capacidad de generalización de los modelos en tareas de análisis de imágenes médicas [?].

En este contexto, las redes neuronales convolucionales (CNNs) han demostrado ser especialmente eficaces en el análisis y procesamiento de imágenes médicas, permitiendo la automatización de tareas complejas con niveles de precisión comparables, e incluso superiores, a los expertos humanos en ciertas aplicaciones.

En el ámbito de la imagen médica, la IA ha impulsado avances significativos en tareas como la detección, clasificación y segmentación de estructuras anatómicas, optimizando los flujos de trabajo

clínicos y facilitando la toma de decisiones en entornos hospitalarios. La capacidad de los algoritmos para identificar patrones invisibles al ojo humano ha revolucionado la radiología y otras disciplinas médicas, permitiendo diagnósticos más precisos y la detección temprana de patologías. Tecnologías como U-Net [?], nnU-Net[?] y Transformers en visión médica [?] han mejorado la segmentación automática de tejidos y órganos, mientras que <sup>o/n</sup>modelos <sup>también</sup> basados en redes profundas han permitido la clasificación automática de imágenes en modalidades como radiografías, tomografías computarizadas (TC) y resonancias magnéticas (RM).

Además, la integración de la IA en el ámbito clínico ha abierto nuevas posibilidades en la planificación quirúrgica personalizada, permitiendo a los cirujanos acceder a reconstrucciones tridimensionales precisas de la anatomía del paciente. Estos avances han mejorado la seguridad y la eficiencia de los procedimientos quirúrgicos, reduciendo el margen de error y optimizando la preparación preoperatoria.

A pesar de los logros alcanzados, persisten desafíos importantes en la implementación clínica de la IA, incluyendo la necesidad de bases de datos de alta calidad, la validación regulatoria de los modelos y la interpretabilidad de los resultados. El presente trabajo busca abordar estos desafíos mediante el desarrollo de una herramienta basada en IA para la clasificación y segmentación automatizada de imágenes de RM en pacientes oncológicos, con el fin de mejorar la precisión diagnóstica y optimizar la planificación quirúrgica.

Cita de ejemplo [1]. ?

• como el título. (Habría el título debería ser clasificación y segmentación)  
Supongo que la intro no está terminada. Falta indicar un parrafo sobre RM y su importancia en la medicina en general y su importancia en el manejo de imágenes médicas con IA en particular.

## 1.2 Principios de las Imágenes Médicas y la Resonancia Magnética

### 1.2.1 Imágenes Médicas

Radiológicas | Ventajas e inconvenientes de ambas modalidades  
No Radiológicas

Las imágenes médicas desempeñan un papel fundamental en la práctica clínica y la investigación biomédica, permitiendo la evaluación no invasiva de la anatomía y fisiología del cuerpo humano. Existen diversas modalidades de adquisición de imágenes médicas, cada una con aplicaciones específicas según el tipo de tejido o patología a evaluar. Entre las principales técnicas se encuentran:

- R** • Radiografía (RX): Basada en la atenuación diferencial de los rayos X, es ampliamente utilizada para el diagnóstico de fracturas óseas y patologías pulmonares [?].
- R** • Tomografía Computarizada (TC): Emplea múltiples proyecciones de rayos X para generar imágenes seccionales del cuerpo, permitiendo una mejor caracterización de estructuras óseas y tejidos blandos [?].
- NR** • Ultrasonido (US): Utiliza ondas sonoras de alta frecuencia para obtener imágenes en tiempo real, siendo de gran utilidad en obstetricia, cardiología y evaluación de tejidos superficiales [?].
- R** • Medicina Nuclear (PET y SPECT): Requiere la administración de radiofármacos que emiten radiación gamma, permitiendo el estudio de procesos metabólicos y la detección de enfermedades como el cáncer [?].

R • Fluoroscopia

- NR • Resonancia Magnética (RM): Basada en la interacción entre un campo magnético externo y los protones presentes en los tejidos, es una técnica avanzada que ofrece imágenes de alta resolución sin el uso de radiación ionizante [?].

Problema: no portable en campo. Caree.

→ muy importante → técnica no invasiva a diferencia de las Radiológicas

Entre estas modalidades, la Resonancia Magnética (RM) ha demostrado ser especialmente útil en la evaluación de tejidos blandos, permitiendo la identificación de estructuras anatómicas con un alto nivel de detalle [?]. Su capacidad para generar distintos contrastes mediante variaciones en los parámetros de adquisición la convierte en una herramienta esencial en el diagnóstico de enfermedades neurológicas, musculoesqueléticas y oncológicas [?].

### 1.2.2 Principio de RM

La RM se basa en la propiedad física del spin nuclear, un fenómeno cuántico asociado a los protones de los átomos de hidrógeno. Al colocar un paciente dentro de un campo magnético estático ( $B_0$ ) generado por el equipo de RM, los protones de hidrógeno se alinean en paralelo o antiparalelo a dicho campo, creando una magnetización neta en la dirección del campo externo [?].

A veces es difícil pero intenta que el tamaño de esta sea igual de grande que la del texto.




Figure 1.1: Descripción de la imagen → label / fig: RM.

poner en español con el paquete babel

A continuación, se emite un pulso de radiofrecuencia (RF) con una frecuencia específica (frecuencia de Larmor), lo que provoca que los protones absorban energía y cambien su alineación. Cuando cesa la excitación, los protones regresan a su estado de equilibrio, emitiendo señales electromagnéticas que son captadas por las antenas del equipo de RM [?].

La ecuación de Larmor muestra la relación de

$$\omega = \gamma \cdot B_0$$

¿qué significa o es la referencia de la ecuación?

Esta ecuación debe ser referenciada en el párrafo

(1.1)

donde:

- $\omega$  es la frecuencia de Larmor (en Hz)
- $\gamma$  es la razón giromagnética del protón ( $\gamma \approx 42.58 \text{ MHz/T}$  para el hidrógeno).
- $B_0$  es la intensidad del campo magnético (en Tesla).

¿muchas distancias?

El retorno a la alineación original se describe mediante dos tiempos de relajación:

- Tiempo de Relajación Longitudinal (T1): Representa el tiempo que tardan los protones en recuperar su alineación con el campo magnético externo.
- Tiempo de Relajación Transversal (T2): Describe la pérdida de coherencia entre los protones debido a interacciones entre ellos.

Estos parámetros determinan el contraste de la imagen y permiten la diferenciación entre distintos tipos de tejidos.




Figure 1.2: Recovery of longitudinal magnetization (T1) and decay of transverse magnetization (T2).

### 1.2.3 Ponderaciones en T1 y T2 en Resonancia Magnética

La manipulación de los tiempos de excitación y detección permite obtener imágenes con distintos contrastes, siendo las secuencias ponderadas en T1 y T2 las más utilizadas en el análisis de tejidos blandos [?].

#### Imágenes ponderadas en T1

Las imágenes ponderadas en T1 se caracterizan por un tiempo de repetición (TR) corto y un tiempo de eco (TE) corto, lo que favorece la recuperación de la magnetización longitudinal y la atenuación de la señal proveniente de tejidos con tiempos de relajación T1 prolongados.

- Tejidos con T1 corto (grasa, sustancia blanca): Presentan una señal intensa, apareciendo brillantes en la imagen.
- Tejidos con T1 largo (líquidos como el líquido cefalorraquídeo - LCR): Generan una señal débil, apareciendo oscuros.






Figure 1.3: Imagen Abdominal RM ponderada en T1 *— Sin referencia*

### Imágenes ponderadas en T2

Las imágenes ponderadas en T2 emplean un TR largo y un TE largo, lo que permite la detección de tejidos con tiempos de relajación T2 prolongados [?].

- Tejidos con T2 largo (líquidos, inflamaciones, edemas): Se visualizan con una señal intensa, apareciendo brillantes en la imagen.
- Tejidos con T2 corto (grasa, sustancia blanca): Presentan menor intensidad de señal, apareciendo oscuros.

*Yo mira ambas imágenes*

long T1	long T2



Figure 1.4: Imagen Abdominal RM ponderada en T2 *— Sin referencia*

La diferenciación entre imágenes ponderadas en T1 y T2 es esencial para el diagnóstico y planificación clínica, ya que cada modalidad proporciona información complementaria sobre las características tisulares.

#### 1.2.4 Importancia de la clasificación de imágenes en T1 y T2

La correcta clasificación de imágenes T1 y T2 es un desafío en la práctica clínica, dado que la variabilidad en los protocolos de adquisición puede generar contrastes similares entre ambas modalidades. Tradicionalmente, esta clasificación ha sido realizada de manera manual por especialistas en radiología, lo que implica un proceso sujeto a variabilidad del observador y consumo de tiempo.

En este contexto, el desarrollo de herramientas basadas en inteligencia artificial para la clasificación automática de imágenes T1 y T2 representa una solución innovadora con el potencial de optimizar los flujos de trabajo en radiología. Al aplicar modelos de aprendizaje profundo, es posible diferenciar ambas modalidades con alta precisión, permitiendo la segmentación automática de estructuras anatómicas de manera más eficiente y personalizada.

La integración de un sistema de clasificación automático previo a la segmentación podría suponer una mejora en la precisión del modelo, evitando errores que podrían surgir al aplicar un mismo algoritmo de segmentación sin considerar las diferencias en contraste entre imágenes ponderadas en T1 y T2. Este enfoque representa un avance en la planificación quirúrgica asistida por IA, proporcionando herramientas más robustas para la toma de decisiones clínicas.

### 1.3 Objetivos del Trabajo

El objetivo de este Trabajo de Fin de Grado es desarrollar una herramienta basada en inteligencia artificial para la clasificación y segmentación automatizada de imágenes de resonancia magnética en planificación quirúrgica. Para ello, se implementarán redes neuronales convolucionales (CNN) capaces de diferenciar entre imágenes T1 y T2, así como modelos de segmentación específicos para cada tipo de imagen, permitiendo una identificación más precisa de las estructuras anatómicas. En el siguiente <sup>Capítulo</sup> apartado, se analizará el estado del arte en el uso de inteligencia artificial para la segmentación y clasificación de imágenes médicas, revisando los avances más relevantes en la aplicación de estas tecnologías. <sup>Es el Capítulo 3, ...</sup>

*falta indicando el resto de capítulos dando una idea general de lo que se va a contar.*

En mi opinión este capítulo no es el estado del arte, es más bien una introducción a redes neuronales que se introduce en medicina mucho antes al capítulo de introducción.

## Estado del arte

### 2.1 Introducción

2.1 Introducción es muy poco

A continuación, se va a realizar un repaso del estado del arte de la inteligencia artificial y su aplicación en la Medicina, desde modelos de segmentación a modelos de clasificación.

Yo añadiría un mini resumen de todo el capítulo.

### 2.2 Inteligencia Artificial en ~~Medicina~~

el análisis de imágenes médicas

#### 2.2.1 Evolución de la IA en Imágenes Médicas

El procesamiento de imágenes médicas ha evolucionado significativamente con la incorporación de técnicas de inteligencia artificial. Desde los primeros métodos basados en algoritmos tradicionales hasta el auge del aprendizaje profundo (deep learning), la segmentación y clasificación de imágenes han experimentado avances sustanciales en precisión y automatización.

#### Primeros enfoques: Métodos tradicionales de segmentación y clasificación

Los primeros enfoques de segmentación de imágenes médicas se basaban en técnicas matemáticas y estadísticas sin la intervención de modelos de aprendizaje automático. Algunos de los métodos más representativos fueron:

Alguna imagen explicativa de los métodos?

- Umbralización (Thresholding): Técnica basada en la separación de regiones de interés mediante la definición de un valor de intensidad umbral. Aunque es eficiente y computacionalmente simple, su principal limitación es su sensibilidad a la iluminación y variaciones de contraste [?].
- Crecimiento de regiones (Region Growing): Algoritmo que expande regiones a partir de píxeles semilla con características similares. Este método mejora la segmentación respecto a la umbralización, pero es susceptible al ruido y la selección del punto de inicio [?].
- Contornos activos (Active Contours o Snakes): Modelos basados en energía que ajustan una curva a los bordes de un objeto en la imagen. Estos métodos son efectivos para segmentaciones suaves y continuas, pero pueden requerir ajustes manuales significativos [?].

Aunque estas técnicas fueron ampliamente utilizadas, presentaban limitaciones en la segmentación de estructuras complejas y en su capacidad de generalización para diferentes modalidades de imagen médica.

## *Métodos basados en Machine Learning en la segmentación y clasificación* **Introducción del Machine Learning en imágenes médicas** *algunos métodos son de clasificación y otros más dirigidos a la segmentación*

Con el auge del aprendizaje automático (Machine Learning, ML), se comenzaron a desarrollar enfoques más robustos para la segmentación y clasificación de imágenes médicas. Algunos de los algoritmos más utilizados fueron:

*Me faltan ejemplos y pro y contra de cada método.*

- Support Vector Machines (SVM): Técnica basada en la búsqueda de un hiperplano óptimo para clasificar datos. Se utilizó en la clasificación de tejidos y detección de tumores, pero su rendimiento dependía en gran medida de la selección de características adecuadas [?].
- Random Forests (RF): Algoritmo basado en la combinación de múltiples árboles de decisión, utilizado en la detección de patrones en imágenes médicas. Si bien ofrece buenos resultados, su desempeño se ve afectado por la calidad de los atributos extraídos manualmente [?].

Estos enfoques mejoraron la segmentación y clasificación en comparación con los métodos tradicionales, pero aún requerían la *selección* ~~extracción~~ manual de características y dependían de la parametrización adecuada para cada tipo de imagen.

## *Métodos basados en Deep Learning en la segmentación y clasificación* **Revolución del Deep Learning y su impacto en imágenes médicas**

La llegada del aprendizaje profundo (Deep Learning, DL) supuso un cambio radical en la segmentación y clasificación de imágenes médicas. A diferencia de los métodos anteriores, las redes neuronales profundas pueden aprender automáticamente las características más relevantes sin necesidad de ingeniería manual de características.

- *fully connected (MLP)* *logit* *classification* *• CNN* *• GAN (generative adversarial)* *• RNN* *• Autoencoders* *• LSTM* *• Transformers* *y dando un ejemplo de cada uno.*
- Redes Neuronales Convolucionales (CNNs): Algoritmos capaces de extraer características jerárquicas de las imágenes, permitiendo una clasificación y segmentación más precisa [39]. adecuadas [?].
- Modelos U-Net y variantes: Arquitecturas especializadas en la segmentación de imágenes biomédicas, como U-Net y nnU-Net, que han demostrado un rendimiento superior en segmentación automática de tejidos y órganos.
- Transformers en visión médica: Técnicas más recientes basadas en autoatención, como los Vision Transformers (ViTs), que han mejorado la segmentación en imágenes médicas con menos dependencia de grandes volúmenes de datos etiquetados.

El impacto del deep learning ha sido tan significativo que ha permitido el desarrollo de modelos autoajustables, reduciendo la necesidad de intervención manual y mejorando la reproducibilidad de los resultados en distintos centros hospitalarios.

*Es casi toda imagen médica excepto US y MRI*

### **2.2.2 Aplicaciones de la IA en Radiología y Resonancia Magnética**

*Imagenes medicas o sin ser todo RM.*

La inteligencia artificial ha revolucionado el campo de la radiología y la resonancia magnética (RM), permitiendo la automatización de tareas complejas que anteriormente requerían intervención manual. Sus aplicaciones abarcan desde la detección temprana de patologías hasta la planificación quirúrgica avanzada, facilitando el análisis de grandes volúmenes de datos con alta precisión y reduciendo la variabilidad interobservador.

Si es en imágenes Médicas:  
 Yo lo dividía en 5 partes:  
 1) Detección y diagnóstico de enfermedades  
 2) Segmentación  
 3) Planificación de cirugías y tratamientos  
 4) Seguimiento de enfermedades  
 5) Mejora y Reconstrucción de imágenes

Enfermedades neurodegenerativas:  
 Oculología  
 Oftalmología  
 Dermología  
 Hay muchas más aplicaciones de la IA.  
 Detección de malformaciones (corazón, ligamento, etc)  
 etc.

Enfermedades neurodegenerativas:  
 Oculología  
 Oftalmología  
 Dermología  
 Hay muchas más aplicaciones de la IA.  
 Detección de malformaciones (corazón, ligamento, etc)  
 etc.

## Detección de tumores y patologías oncológicas

Los modelos basados en redes neuronales convolucionales (CNNs) han demostrado un gran potencial en la identificación de tumores en diversas modalidades de imágenes médicas, incluidas las imágenes de resonancia magnética. Algunos ejemplos incluyen:

- Diagnóstico de tumores cerebrales: Modelos como U-Net y nnU-Net han sido utilizados para la segmentación automática de tumores cerebrales en imágenes de RM ponderadas en T1 y T2, mejorando la detección de gliomas y metástasis cerebrales [?].
- Cáncer de mama: Sistemas de IA han logrado identificar lesiones sospechosas en imágenes de resonancia magnética de mama, reduciendo falsos positivos y mejorando la precisión en la detección temprana [?].
- Tumores pancreáticos: Estudios recientes han demostrado que el uso de IA en imágenes de RM puede mejorar la caracterización y clasificación de lesiones pancreáticas, facilitando el diagnóstico diferencial entre tumores benignos y malignos [?].

## Detección de enfermedades neurodegenerativas y musculoesqueléticas

Además del diagnóstico oncológico, la IA ha sido aplicada en la detección de enfermedades como:

- Alzheimer y Esclerosis Múltiple: Modelos basados en Deep learning han sido empleados para el análisis de volúmenes cerebrales y la detección de patrones asociados con el deterioro cognitivo temprano [?].
- Osteoartritis: Algoritmos de segmentación automática han sido utilizados en resonancia magnética de articulaciones para detectar cambios degenerativos en cartílago y tejido óseo [?].

## 2.3 Modelos de Segmentación de Imágenes Médicas

La segmentación de imágenes médicas es un proceso fundamental en la interpretación y análisis de imágenes biomédicas, facilitando la identificación de estructuras anatómicas y patológicas. A lo largo del tiempo, se han desarrollado diversos enfoques, desde métodos tradicionales basados en reglas matemáticas hasta modelos avanzados basados en aprendizaje profundo (deep learning).

### 2.3.1 Modelos Convencionales

Los métodos tradicionales de segmentación han sido utilizados ampliamente en el análisis de imágenes médicas, empleando técnicas matemáticas y estadística para identificar regiones homogéneas dentro de una imagen.

#### Métodos tradicionales de segmentación

- Segmentación basada en umbralización: Separa regiones de una imagen en función de un valor umbral, lo que la hace eficaz en imágenes con contraste bien definido. Sin embargo, presenta dificultades en la segmentación de estructuras complejas con variabilidad en la intensidad [?].



- **Método Watershed:** Basado en el concepto de cuencas hidrográficas, este método es útil para segmentar imágenes con bordes bien definidos, aunque es propenso a la sobresegmentación en imágenes con ruido o estructuras anatómicas adyacentes [?].
- **Clustering K-Means:** Técnica de agrupamiento no supervisado que divide los píxeles en diferentes regiones en función de su similitud en intensidad. Sin embargo, su rendimiento depende de la selección del número de clases y es sensible a variaciones en contraste [?].
- **Modelos de contornos activos (Active Contours o Snakes):** Utilizan curvas que se ajustan a los bordes de los objetos en la imagen. Aunque son eficaces para la segmentación de estructuras anatómicas con límites suaves, requieren inicialización manual y pueden verse afectados por ruido en la imagen [?].

### Limitaciones de los métodos tradicionales frente a Deep Learning

Los enfoques convencionales presentan varias limitaciones que han impulsado la adopción de técnicas basadas en aprendizaje profundo:

- **Dependencia de parámetros manuales:** Requieren ajuste manual de umbrales y semillas iniciales.
- **Baja adaptabilidad:** Son sensibles a cambios en contraste y ruido.
- **Capacidad limitada de generalización:** No se adaptan bien a conjuntos de datos diversos sin ajustes específicos.

El desarrollo de redes neuronales convolucionales (CNNs) ha permitido abordar estas limitaciones mediante la automatización del proceso de segmentación y un incremento significativo en la precisión y robustez de los modelos.

### 2.3.2 Redes Neuronales Convolucionales (CNNs) en Segmentación Médica

Las redes neuronales convolucionales (CNNs) han revolucionado la segmentación de imágenes médicas al permitir el aprendizaje automático de características relevantes directamente desde los datos de entrada, sin necesidad de una extracción manual de características.

#### Explicación básica de las CNNs

Las CNNs se componen de múltiples capas de procesamiento, incluyendo:

- **Capas de convolución:** Aplican filtros sobre la imagen para extraer características como bordes y texturas.
- **Capas de pooling:** Reducen la dimensionalidad de la imagen manteniendo las características más relevantes.
- **Capas totalmente conectadas:** Integran la información extraída y generan la predicción final de segmentación [?].

*— Muy pobre, imágenes.  
Las CNN son muy impotentes y se basan  
de las demás  
Explica algo más que sea  
explicativo*




Figure 2.1: descripción de la imagen

*Este capítulo debería ordenarlo mas*

## 2.4 Modelos clave en segmentación médica

### 2.4.1 U-Net: Arquitectura y aplicaciones en segmentación médica

El modelo U-Net es una arquitectura de red neuronal convolucional desarrollada en 2015 por Olaf Ronneberger y su equipo, diseñada específicamente para la segmentación de imágenes biomédicas. Su estructura en forma de "U" consta de dos caminos principales:

1. Camino de Contracción (Encoder): Este segmento captura el contexto de la imagen mediante la aplicación repetida de convoluciones seguidas de funciones de activación y operaciones de pooling. A medida que se avanza en este camino, la resolución espacial disminuye mientras que la profundidad de las características aumenta, permitiendo una representación más abstracta de la información.
2. Camino de Expansión (Decoder): En esta sección, la resolución de la imagen se restaura progresivamente. Se emplean operaciones de upsampling y convoluciones para aumentar la resolución, incorporando conexiones de salto que transfieren información detallada desde las capas correspondientes del encoder. Estas conexiones son cruciales para recuperar detalles espaciales que podrían haberse perdido durante la fase de contracción.




Figure 2.2: Arquitectura de la UNet

Can?

Aunque el U-Net ha demostrado ser altamente efectivo, su implementación puede requerir ajustes manuales significativos para adaptarse a diferentes conjuntos de datos y tareas específicas. Para abordar esta limitación, se desarrolló el nnU-Net ("no-new-Net"), un marco autoajustable que automatiza la configuración de la arquitectura U-Net según las características del conjunto de datos proporcionado. El nnU-Net analiza los casos de entrenamiento y configura automáticamente una tubería de segmentación basada en U-Net, eliminando la necesidad de intervención manual en aspectos como el preprocesamiento, configuración del modelo, entrenamiento y posprocesamiento. Esta automatización no solo facilita su uso, sino que también ha demostrado rendir resultados de vanguardia en múltiples desafíos de segmentación médica.

En resumen, mientras que el U-Net original sentó las bases para la segmentación de imágenes médicas, el nnU-Net ha optimizado y automatizado este proceso, adaptándose dinámicamente a diversas tareas y conjuntos de datos sin requerir ajustes manuales extensivos.

Aquí lo dejé de seguir leyendo ya que en realidad no es el estado del arte. Si no una introducción al uso de redes en el ámbito de las imágenes médicas.

## 2.5 Modelos de Clasificación de Imágenes Médicas

### 2.5.1 Modelos de Aprendizaje Profundo para Clasificación

El análisis y clasificación de imágenes médicas han evolucionado considerablemente con el uso del aprendizaje profundo, en particular con las redes neuronales convolucionales (CNN). Estos modelos han demostrado una gran capacidad para extraer patrones complejos y diferenciar entre diferentes tipos de imágenes médicas, como resonancias magnéticas (RM), tomografías computarizadas (TC) y radiografías.



### **2.5.2 Redes CNN estándar y su uso en clasificación de imágenes médicas**

Las CNN estándar están compuestas por múltiples capas de convolución, seguidas de capas de pooling y capas totalmente conectadas. En la clasificación de imágenes médicas, estas redes se han utilizado para tareas como la detección de tumores, el diagnóstico de enfermedades pulmonares y la identificación de anomalías en imágenes de resonancia magnética. Entre las arquitecturas tradicionales se encuentran AlexNet y LeNet, las cuales fueron las primeras en demostrar el potencial del aprendizaje profundo en la clasificación de imágenes.

### **Modelos avanzados (ResNet, DenseNet, VGG) y su desempeño en RM**

A medida que la complejidad de las imágenes médicas ha aumentado, se han desarrollado modelos más sofisticados como:

- **ResNet (Redes Residuales):** Introducen conexiones residuales que permiten entrenar redes más profundas sin sufrir el problema de la desaparición del gradiente. En imágenes de RM, han mejorado la precisión en la detección de anomalías estructurales.
- **DenseNet:** Conexiones densas entre capas que facilitan la reutilización de características y mejoran la eficiencia del entrenamiento. Se han aplicado con éxito en la segmentación y clasificación de tejidos en imágenes médicas.
- **VGG (Visual Geometry Group):** Caracterizada por su simplicidad y uso de múltiples capas convolucionales de pequeño tamaño, ha sido ampliamente utilizada en la clasificación de resonancias magnéticas cerebrales. .

### **Enfoques híbridos: uso combinado de segmentación y clasificación**

En algunos casos, la clasificación de imágenes médicas se beneficia del uso combinado de segmentación y clasificación. Estos modelos híbridos primero segmentan las regiones de interés en la imagen (por ejemplo, una lesión o un tumor) y luego clasifican la región segmentada para mejorar la precisión del diagnóstico. Este enfoque es particularmente útil en imágenes de resonancia magnética y tomografía computarizada, donde las estructuras anatómicas pueden ser difíciles de diferenciar.



## *Appendix A*

---

# **Additional**

---

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum.



---

# Bibliography

---

- [1] Albert Einstein. Zur Elektrodynamik bewegter Körper. (German) [On the electrodynamics of moving bodies]. *Annalen der Physik*, 322(10):891–921, 1905.